

COVID-19 Sebepli Uzaktan Eğitimin Öğrenci Duygu Analizi

Ecem Nilay Bazman

Abstract—Corona Virüs Hastalığı 2019 (COVID-19) salgını nedeniyle çeşitli ülkelerde geleneksel yüz yüze eğitim ve öğretim çevrimiçi/uzaktan eğitim platformlarına taşınmıştır. Bu durum eğitimin kalitesini doğrudan etkilemiştir. Bu dokümanda, öğrencilerin bu eğitim düzeni hakkındaki duyguları analiz edilmeye çalışılmıştır. Çevrimiçi/uzaktan eğitimde öğrenci duygu analizini yapabilmek için uzaktan eğitim düzeni hakkındaki öğrencilerin Twitter yorumları kullanılmıştır. Bu analizin yapılabilmesi için doğal dil işleme, metin analizi ve yapay sinir ağları ile oluşturulan modeller kullanılmıştır.

I. GİRİŞ

Bu çalışmada, COVID-19 pandemisi süresinde uygulanan çevrimiçi/uzaktan eğitim düzeni hakkındaki tweetler öğrenci yorumu olarak kabul edilip, doğal dil işleme, metin analizi ve hesaplamalı dilbilimi kullanılarak duygu analizi yapılmıştır. Twitter ile elde edilen yorumlardan İngilizce yorumlar seçilerek üç duygu sınıfına (olumlu, olumsuz ve nötr) ayrılarak analiz yapılmıştır.

II. VERİ SETİ

Veri seti, COVID-19 pandemi süresinde çevrimiçi/uzaktan eğitim hakkında Twitter üzerinden yayınlanan 100.000 adet yorumu içermektedir.

A. Başlangıçtaki Veri Seti

Veri seti, Twitter üzerinden çevrimiçi/uzaktan eğitim ile ilgili yapılan 100.000 adet farklı dilden yorum, Tweet numarası, Tweet atan kullanıcı adını, Tweet atıldığı tarihi ve zamanı içermektedir. Veri setine ait genel görünüm Fig. 1’de verilmiştir. Verinin doğal dil işleme ve metin analizinin sağlıklı yapılabilmesi için sayısal verilerin (tarih ve saat gibi), anlamsız ASCII olmayan özel karakterlerin (Twitter üzerinden veri çekilirken String dönüşümü yapılamayan karakterler) ve noktalama işaretlerinin temizlenmesi gerekmektedir. Ayrıca amaca uygun olabilmesi için İngilizce yorumlar filtrelenmelidir.

B. Veri Temizlenmesi ve Filtrelenmesi

Çalışmalarda kullanılması uygun olacak şekilde metin madenciliği işlemlerinden (sayı verisinin, noktalama işaretlerinin ve engellenecek kelimelerin temizlenmesi) geçirilerek veri temizlenmiştir. Engellenecek kelimelerin genel bir listesinin kullanılması, duyarlılık analizi performansı üzerinde olumsuz bir etkiye sahip olabileceğinden [1], olumsuz anlam taşımayan yeni bir engellenecek kelime listesi oluşturulmuştur. Ayrıca ASCII olmayan karakterler de temizlenmiştir. Lemmi fonksiyonu ile kelimeler kök sözcüklere indirgenerek

Bu çalışma, İstanbul Kültür Üni. Bilgisayar Mühendisliği Tezli YL Programı, Yapay Zeka dersi proje raporudur.

Tweets

0	1357048805078794240	2021-02-03 22:30:22 +0300 ...
1	1357047758457290753	2021-02-03 22:26:13 +0300 ...
2	1357046304602546177	2021-02-03 22:20:26 +0300 ...
3	1357045817375248384	2021-02-03 22:18:30 +0300 ...
4	1357045182924005378	2021-02-03 22:15:58 +0300 ...
...
99994	1324730409243103233	2020-11-06 18:08:36 +0300 ...
99995	1324730331308675074	2020-11-06 18:08:17 +0300 ...
99996	1324729616527986688	2020-11-06 18:05:27 +0300 ...
99997	1324729115539345409	2020-11-06 18:03:28 +0300 ...
99998	1324729108723650565	2020-11-06 18:03:26 +0300 ...

99999 rows × 1 columns

Fig. 1. Başlangıçtaki Veri Seti

kelime frekansının daha başarılı belirlenmesine alt yapı oluşturulmuştur. Amaca uygun olabilmesi için İngilizce dışında başka dillerden çekilen yorumlar da ayırt edilip temizlenmiş ve 75042 adet yorum kalmıştır.

III. AMAÇ

Çalışmanın amacı, Veri setinde bulunan Twitter üzerinden çevrimiçi/uzaktan eğitim ile ilgili yapılan 100.000 adet farklı dildedeki yorumlardan İngilizce yorumlar filtrelenerek öğrencilerin çevrimiçi/uzaktan eğitim ile duygu analizini yapmaktır.

IV. VERİ İŞLEME

Metin madenciliğinde Polarite, [-1,1] aralığında yer alan floattır; burada 1, pozitif ifade ve -1, negatif bir ifade anlamına gelir. Özne cümleler genellikle kişisel görüş, duygu veya yargıya atıfta bulunurken, nesnel bilgiler gerçek bilgilere atıfta bulunur. Öznellik aynı zamanda [0,1] aralığında yer alan bir dalgalanmadır. Veri setindeki yorumların Polarite ve Öznellik özelliklerine de bakılmıştır. Polarite analizi ile duygu sınıfları sütunu oluşturulmuştur. Duygu sınıfı kolonu sözel veriler içermesi nedeniyle sayısal veriye dönüştürülmesi için Encoding işlemi uygulanmıştır ve "Duygu Sınıfı enc" sütunu oluşturulmuştur. Duygu dağılımları Fig. 2’de verilmiştir.




Fig. 2. Duygu Dağılımı

Sonuç olarak, işlenen veri Fig. 3’de ve bu veri setine ait kelime bulutu Fig. 4’de verilmiştir.

	index		Tweets	Polarity	Subjectivity	Duygu_Sinifi	Duygu_Sinifi_eng	
	0	2	elearning erlaubt	0.000000	0.000000	Notr		1
	1	4	training space impoant professional working fa...	0.100000	0.200000	Pozitif		2
	2	7	made first internet dollar year half ago conve...	-0.014881	0.297619	Negatif		0
	3	9	anaesthesia elearning programme elearning sess...	0.400000	0.575000	Pozitif		2
	4	11	look like interesting course format sell in as...	0.413333	0.580000	Pozitif		2
		
75037	99994		student take elearning bank	0.000000	0.000000	Notr		1
75038	99995		xiaomi launch affordable mi notebook clearing...	0.000000	0.000000	Notr		1
75039	99996		want free place globally recognised safety hea...	0.200000	0.400000	Pozitif		2
75040	99997		social distancing requirement caused people sp...	-0.016667	0.316667	Negatif		0
75041	99998		example tab menu navigation elearning	0.000000	0.000000	Notr		1

75042 rows x 6 columns

Fig. 3. Ön İşlemler Sonrası Veri Seti



Fig. 4. Kelime Bulutu

Duygu analizi yapılabilmesi için kullanılacak veri, Twitter yorumları olması nedeniyle sözel yapıdadır. Bu verinin yapay zeka modelleri kullanılarak duygu analizi yapılabilmesi için sayısal verilere çevrilmesi gerekmektedir. Öncelikle meitndeki kelimelerin kullanım sıklığına göre frekansları bulunmuştur. Kelimelerin frekans analizi Fig. 5’de verilmiştir.

V. YÖNTEM

Veri setinde bulunan yorumlar sayısal verilere dönüştürülebilmesi için tokenleştirme ve vektörleşme işlemleri uygulanmıştır. Bu sayısal veriler de modeli besleyecek şekilde kullanılmıştır.

Tokenleştirme işleminde en sık kullanılan 5000 kelime ele alınmıştır ve Fig. 6'de verilmiştir. Tokenleştirme işlemi keras kullanılarak yapılmıştır. Tokenleştirme örneği bir cümle üzerinden Fig. 7'de verilmiştir.

VEKTÖRLESTİRME	
kelime	frekansları
elearning	6639, 161320
course	1538, 270297
school	1234, 108718
day	1119, 699739
student	1032, 218218
learning	964, 441416
online	910, 209879
platform	868, 510985
new	840, 374784
free	733, 253541
training	731, 237698
get	727, 018072
via	688, 901685
today	678, 979769
kid	636, 712088
work	631, 583660
time	626, 266342
education	624, 128548
help	565, 752939
need	563, 294383

Fig. 5. Kelime Frekansları

```
In [152]: tokenizer.word_index

Out[152]: {'learning': 1,
            'course': 2,
            'school': 3,
            'day': 4,
            'student': 5,
            'learning': 6,
            'online': 7,
            'new': 8,
            'not': 9,
            'platform': 10,
            'get': 11,
            'training': 12,
            'free': 13,
            'time': 14,
            'today': 15,
            'work': 16,
            'kid': 17,
            'education': 18,
            'help': 19,
            'need': 20}
```

Fig. 6. Tokenleştirme (5000 kelime ile)

A. Eğitim ve Test Setinin Oluşturulması

Veri setindeki temizlenen yorumlar (75042 adet), yüzde 70'i eğitim verisi yüzde 30'si test verisi olacak şekilde bölünmüştür.

B. Model Oluşturulması

Yapay zeka modelleri girdi olarak belirli sayıda girdi almaktadır. Yorumları girdi olarak bir RNN modeline verebilmek için boyutları eşitlenmiştir (maxlen=52). Öncelikle sıralı bir model oluşturulmuştur. Oluşan modelin doğruluk değerleri Fig. 8’de görüldüğü gibi yeterli değildir. Sıralı olmayan model üzerinde yapılan denemeler de Fig. 9’de görüldüğü gibi çok farklı bir sonuç elde edilememiştir.

Oluşturulan modellerde kayıp değerleri binary cross-entropy yerine categorical crossentropy ile bakıldığında da kayda değer bir değişiklik olmadığından sparse categorical crossentropy ile tekrar deneme modelleri oluşturularak optimizasyon yapıldı. NN modelde belirli bir katmandaki birimlerin aktivasyonlarını, ağırlıkları ve verileri değiştirilerek modelin doğruluğu test edildi. Özellik değeri (feature), ağırlık girişi katmanındaki düğüm sayısına eşit olduğu için bu

```
In [56]: x_train_tokens = tokenizer.texts_to_sequences(x_train)
x_test_tokens = tokenizer.texts_to_sequences(x_test)

num_tokens = [len(tokens) for tokens in x_train_tokens + x_test_tokens]

In [57]: x_train[800]
Out[57]: 'like family elearning worked fine think rural kid dont exist'

In [58]: print(x_train_tokens[800])
[32, 132, 1, 741, 1363, 150, 372, 18, 99, 2874]
```

Fig. 7. Tokenleştirme Örneği




Fig. 8. Sıralı Model Doğruluk ve Kayıp Değerlendirmesi

değerin değişmesi modelin doğruluk oranını artırıcı yönde etkilediği gözlemlenmiştir.

Öncelikle kayıp değeri sparse categorical crossentropy olan ve giriş katmanındaki düğüm sayısı (feature) 100 girilerek oluşturulan NN modelinde doğruluk, Fig. 10'deki görüldüğü üzere yüzde 74'e kadar çıkmıştır. Daha sonra kayıp değeri sparse categorical crossentropy olan ve giriş katmanındaki düğüm sayısı (feature) 150 olduğunda modelin doğruluğunun yüzde 80'ne ulaştığı gözlemlenmiştir. DenemeModel3'te kayıp değeri aynı kalmak şartı ile feature değeri 250 yapıldığında yüzde 85 doğruluk değerine ulaşılmıştır. DenemeModel4'te feature değeri 1000 yapıldığında yüzde 95 doğruluk değerine ulaşılmıştır. DenemeModel5'te feature değeri 5000 yapıldığında yüzde 97 doğruluk değerine ulaşılmıştır. Burada bahsedilen doğruluk oranları val accuracy değerleri olup her epoch'ta arttığı gözlemlenmiştir. Aynı epoch değerlerinde kayıpların ise azaldığı Fig. 11'deki gibi gözlemlenmiştir. Böylece modeli eğitim verisi ile aşırı eğitilmemiş olduğu anlaşılmıştır. Fea-

ture değerlerinin artışı ile beraber modellerin girdi sayısının artması modellerin yavaş çalışmasına da neden olmuştur.

```
modelDeneme1 = modelDeneme1(X_train, y_train)

Epoch 1/6
1478/1478 [=====] - 8s 3ms/step - loss: 0.7664 - accuracy: 0.6670 - val_loss: 0.6527 - val_accuracy: 0.7124
Epoch 2/6
1478/1478 [=====] - 5s 3ms/step - loss: 0.6466 - accuracy: 0.7195 - val_loss: 0.6407 - val_accuracy: 0.7202
Epoch 3/6
1478/1478 [=====] - 5s 3ms/step - loss: 0.6335 - accuracy: 0.7285 - val_loss: 0.6284 - val_accuracy: 0.7232
Epoch 4/6
1478/1478 [=====] - 5s 3ms/step - loss: 0.6224 - accuracy: 0.7333 - val_loss: 0.6227 - val_accuracy: 0.7287
Epoch 5/6
1478/1478 [=====] - 5s 3ms/step - loss: 0.6013 - accuracy: 0.7447 - val_loss: 0.6052 - val_accuracy: 0.7401
Epoch 6/6
1478/1478 [=====] - 5s 3ms/step - loss: 0.5877 - accuracy: 0.7531 - val_loss: 0.5961 - val_accuracy: 0.7460
```

Fig. 10. Model 1 (feature=100)

```
modelDeneme5 = modelDeneme5(X_train, y_train)

Epoch 1/10
1478/1478 [=====] - 43s 22ms/step - loss: 0.6029 - accuracy: 0.7411 - val_loss: 0.1738 - val_accuracy: 0.9433
Epoch 2/10
1478/1478 [=====] - 32s 22ms/step - loss: 0.1259 - accuracy: 0.9617 - val_loss: 0.1315 - val_accuracy: 0.9617
Epoch 3/10
1478/1478 [=====] - 32s 22ms/step - loss: 0.0731 - accuracy: 0.9797 - val_loss: 0.1198 - val_accuracy: 0.9682
Epoch 4/10
1478/1478 [=====] - 30s 20ms/step - loss: 0.0436 - accuracy: 0.9886 - val_loss: 0.1257 - val_accuracy: 0.9686
Epoch 5/10
1478/1478 [=====] - 31s 21ms/step - loss: 0.0263 - accuracy: 0.9935 - val_loss: 0.1369 - val_accuracy: 0.9718
Epoch 6/10
1478/1478 [=====] - 31s 21ms/step - loss: 0.0181 - accuracy: 0.9956 - val_loss: 0.1500 - val_accuracy: 0.9711
Epoch 7/10
1478/1478 [=====] - 33s 22ms/step - loss: 0.0124 - accuracy: 0.9967 - val_loss: 0.1491 - val_accuracy: 0.9728
Epoch 8/10
1478/1478 [=====] - 31s 21ms/step - loss: 0.0095 - accuracy: 0.9979 - val_loss: 0.1534 - val_accuracy: 0.9728
Epoch 9/10
1478/1478 [=====] - 29s 20ms/step - loss: 0.0064 - accuracy: 0.9985 - val_loss: 0.1671 - val_accuracy: 0.9714
Epoch 10/10
1478/1478 [=====] - 31s 21ms/step - loss: 0.0071 - accuracy: 0.9985 - val_loss: 0.1792 - val_accuracy: 0.9730
```

Fig. 11. Model 5 (feature=5000)

C. Modelin Test Edilmesi

DenemeModel5'te feature değeri 5000 yapıldığında yüzde 97 doğruluk değerine ulaşılması nedeniyle duygu analizinde kullanılmak için bu model seçilmiştir. Temizlenen veri setinin 30000. verisinden son verisine kadar olan bütün data setinden bir yeni kontrol verisi elde edilmiştir. Bu kontrol verisi model5'e duyguların tahmini için girdi olarak verildiğinde sonuç Fig. 12'deki gözlemlenmiştir.




Fig. 9. Sıralı Olmayan Model Doğruluk ve Kayıp Değerlendirmesi

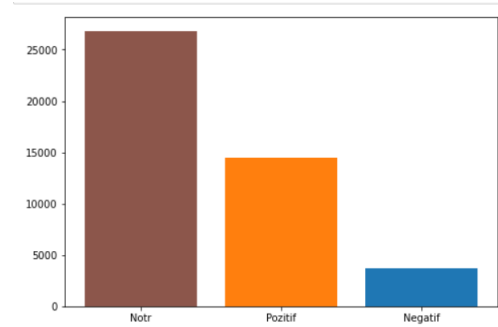


Fig. 12. Duygu Analizi Sonucu

VI. SONUÇ

Bu çalışmada, Covid pandemi dönemi çevrimiçi/uzaktan eğitim ile ilgili Tweetlerden oluşan veri setinden İngilizce yorumların ayıklanarak öğrenci duygu analizi yapılması hedeflenmiştir. Kelime bulutu (Fig. 4) ve kelime frekansları (Fig. 5), bu amaca uygun olarak verilerin temizlenebildiğini ve konu ile birebir örtüştüğünü göstermektedir.

Temizlenen İngilizce yorumlardan pandemi dönemindeki öğrencilerin duygu analizi denemeModel5 kullanılarak yüzde 97 doğruluk oranıyla, çoğunlukla nötr daha sonra da pozitif yorumlar yapıldığı gözlemlenmiştir. Nötr yorumların fazla olmasının nedeni, bu eğitim düzenine bir mecburiyetten dolayı ve aniden geçilmesi olabilir. Duygular belirli bir tecrübe, yaşanmışlık v farkındalık ile oluşur. Alışkın olunmayan durumlarda olumlu veya olumsuz yorum yapılamaması normaldir. Eğer duygu analizini 3 sınıflı değil de 2 sınıflı (olumlu-olumsuz) yapsaydık da yorumların pozitif yönde olacağı söylenebilir.

REFERENCES

- [1] Saif, Hassan; Fernández, Miriam; He, Yulan and Alani, Harith (2014). On stopwords, filtering and data sparsity for sentiment analysis of Twitter. In: LREC 2014, Ninth International Conference on Language Resources and Evaluation. Proceedings., pp. 810–817.